



BURDUR MEHMET AKİF ERSOY ÜNİVERSİTESİ

Göhlisar Uygulamalı Bilimler Yüksekokulu

İLERİ PYTHON PROGRAMLAMA II DERSİ

GRUP İSMİ: AFODEN

PROJE KONUSU: AFO Veri Seti ile YOLOv9 Kullanılarak Deniz Ortamında Küçük Nesne Tespiti

Öğrenci Ad-Soyad:

- 1- İsmail Can Dağ
- 2- Murat Turan
- 3- Doğukan Olağ
- 4- Alperen Kaya
- 5- Zafer Göktaş

MAYIS 2025

BURDUR

ÖNSÖZ

Bu proje raporu, Gölhisar Uygulamalı Bilimler Yüksekokulu'nda İleri Python Programlama II dersi kapsamında yürütülen "AFO Veri Seti ile YOLOv9 Kullanılarak Deniz Ortamında Küçük Nesne Tespiti" başlıklı projenin sonuçlarını sunmak amacıyla hazırlanmıştır. Günümüzde yapay zeka ve derin öğrenme teknolojilerinin hızla gelişmesi, birçok alanda olduğu gibi arama kurtarma operasyonlarında da yeni ufuklar açmaktadır. Özellikle deniz ortamlarında kaybolan veya yardıma ihtiyaç duyan canlıların tespiti, zamanla yarışılan kritik bir süreçtir. Bu projede, insansız hava araçlarından elde edilen görüntüler üzerinde küçük nesnelerin etkili bir şekilde tespit edilebilmesi için modern bir nesne tespit algoritması olan YOLOv9'un kullanılması hedeflenmiştir.

Projenin gerçekleştirilmesi sürecinde, AFO (Aerial Floating Object) adı verilen ve bu tür çalışmalar için özel olarak hazırlanmış bir veri seti kullanılmıştır. YOLOv9 modelinin seçimi, literatürdeki yüksek performansı ve gerçek zamanlıya yakın tespit yetenekleri göz önünde bulundurularak yapılmıştır. Bu çalışmanın, derin öğrenme tabanlı nesne tespiti konusundaki bilgilerimizin pekiştirilmesine katkı sunması beklenmektedir.

Bu projede değerli yönlendirmeleri ve destekleriyle yanımızda olan sayın hocamız Dr. Öğr. Üyesi Nilgün Şengöz'e en içten teşekkürlerimizi sunarım. Ayrıca, proje süresince bilgi ve deneyimlerini paylaşan tüm arkadaşlarıma da teşekkür ederim. Umarız bu rapor, benzer konularda çalışma yapacak diğer öğrencilere de bir kaynak teşkil eder.

İÇİNDEKİLER

ÖNSÖZ	2
İÇİNDEKİLER.....	3
ÖZET	4
ABSTRACT	4
1. GİRİŞ.....	5
2. LİTERATÜR ÖZETİ.....	6
3. GEREÇ VE YÖNTEM	8
3.1. Veri Seti: AFO (Aerial Floating Object)	8
3.2. Nesne Tespit Modeli: YOLOv9.....	9
3.3. Modelin Eğitimi ve Uygulanması	10
3.4. Performans Değerlendirme Metrikleri	10
4. BULGULAR	12
4.1 Model Performansı.....	12
4.2 Kategori Bazında Performans	13
4.3 Tespit Örnekleri	13
5. TARTIŞMA	14
6. SONUÇ VE ÖNERİLER	16
KAYNAKLAR	17

ÖZET

Bu çalışmada, deniz ortamlarında arama kurtarma faaliyetlerine destek olmak amacıyla, AFO (Aerial Floating Object) veri seti kullanılarak küçük nesnelerin tespiti için YOLOv9 derin öğrenme modeli uygulanmıştır. Projenin temel amacı, insansız hava araçları (İHA) ile elde edilen görüntülerdeki insan, bot, sal gibi kritik öneme sahip nesneleri otomatik olarak ve yüksek doğrulukla tanıyabilen bir sistem geliştirmektir. Çalışmada, YOLOv9 modelinin özellikle 'yolov9-c.pt' önceden eğitilmiş ağırlıkları kullanılmıştır. Modelin eğitimi sonucunda, 289. epoch'ta en iyi performansa ulaşılmış; mAP50 değeri 0.9546, mAP50-95 değeri 0.7097, hassasiyet (precision) değeri 0.9339 ve duyarlılık (recall) değeri 0.9214 olarak ölçülmüştür. Elde edilen bu sonuçlar, YOLOv9 modelinin AFO veri setindeki küçük nesneleri tespit etmede yüksek bir potansiyele sahip olduğunu ve literatürdeki benzer çalışmalardan daha yüksek doğruluk oranı ile nesne tespiti yapabildiğini göstermektedir. Bu çalışma, derin öğrenme tabanlı nesne tespit sistemlerinin denizcilikte arama kurtarma operasyonlarının etkinliğini artırma potansiyelini vurgulamaktadır.

Anahtar Kelimeler: Nesne Tespiti, YOLOv9, AFO Veri Seti, Derin Öğrenme, Denizde Arama Kurtarma, Bilgisayarlı Görü

ABSTRACT

In this study, the YOLOv9 deep learning model was applied for the detection of small objects using the AFO (Aerial Floating Object) dataset to support maritime search and rescue operations. The primary aim of the project is to develop a system capable of automatically and accurately identifying critical objects such as humans, boats, and rafts in images acquired by unmanned aerial vehicles (UAVs). Specifically, the pre-trained weights of the YOLOv9 model, 'yolov9-c.pt', were utilized and fine-tuned on the AFO dataset. The model achieved its best performance at the 289rd epoch, with a mAP50 score of 0.9546, a mAP50-95 score of 0.7097, a precision of 0.9339, and a recall of 0.9214. These results indicate that the YOLOv9 model has a high potential for detecting small objects and show that the proposed model can detect objects with a higher accuracy rate than similar studies in the literature within the AFO dataset. This research highlights the potential of deep learning-based object detection systems to enhance the effectiveness of maritime search and rescue operations.

Keywords: Object Detection, YOLOv9, AFO Dataset, Deep Learning, Maritime Search and Rescue, Computer Vision

1. GİRİŞ

Denizlerde meydana gelen kazalar ve kayıp vakaları, arama kurtarma operasyonlarının hızlı ve etkin bir şekilde yürütülmesini zorunlu kılmaktadır. Geleneksel arama yöntemleri genellikle insan gücüne dayalı olup geniş alanların taranmasında zaman alıcı ve maliyetli olabilmektedir. Son yıllarda, yapay zeka, bilgisayarlı görü ve derin öğrenme alanlarındaki hızlı gelişmeler, insansız hava araçları (İHA) ile entegre edilerek arama kurtarma operasyonlarının verimliliğini artırma potansiyeli sunmaktadır [3]. Özellikle İHA'lar tarafından elde edilen yüksek çözünürlüklü hava görüntüleri, geniş alanların kısa sürede taranmasına ve potansiyel hedeflerin tespit edilmesine olanak tanımaktadır.

Bu projenin temel amacı, deniz ortamında yüzen küçük nesnelerin (insan, bot, sal vb.) tespiti için güncel bir derin öğrenme modeli olan YOLOv9'u kullanmaktır. Literatürde, özellikle küçük ve zor ayırt edilebilir nesnelerin tespiti, derin öğrenme modelleri için hala zorlu bir problem olarak kabul edilmektedir. Bu bağlamda, proje kapsamında AFO (Aerial Floating Object) adı verilen ve özellikle bu tür senaryolar için oluşturulmuş kamuya açık bir veri seti kullanılmıştır [3]. AFO veri seti, farklı coğrafi konumlarda ve çeşitli hava koşullarında çekilmiş, üzerinde etiketlenmiş küçük yüzen nesneler içeren binlerce görüntüden oluşmaktadır. Bu veri seti, modelin gerçek dünya koşullarına yakın bir senaryoda eğitilmesi ve test edilmesi için uygun bir zemin sağlamaktadır.



Şekil 1. AFO Veri Setinden Örnek Görüntü

Çalışmada, YOLO (You Only Look Once) algoritmasının en son ve gelişmiş versiyonlarından biri olan YOLOv9 tercih edilmiştir. YOLO algoritmaları, nesne tespiti için tek bir sinir ağı üzerinden gerçekleştirerek hem yüksek doğruluk hem de yüksek hız sunmalarıyla bilinirler. Bu özellikleri, onları gerçek zamanlı veya gerçek zamanlıya yakın uygulamalar için ideal kılmaktadır. Projede, YOLOv9 modelinin önceden eğitilmiş ağırlıklarından biri olan 'yolov9-e.pt' kullanılmış ve modelin performansı değerlendirilmiştir.

Bu rapor, yürütülen projenin detaylarını ve elde edilen sonuçları sunmaktadır. İkinci bölümde, nesne tespiti, YOLO algoritmaları ve AFO veri seti ile ilgili literatürdeki önemli çalışmalara değinilecektir. Üçüncü bölümde, projede kullanılan materyaller (veri seti) ve yöntem (YOLOv9 modeli, eğitim süreci) ayrıntılı olarak açıklanacaktır. Dördüncü bölümde, modelin eğitiminden elde edilen bulgular ve performans metrikleri sunulacaktır. Beşinci bölümde, elde edilen sonuçlar literatür ışığında tartışılacak ve yorumlanacaktır. Son olarak, altıncı bölümde projenin genel bir sonucu çıkarılacak ve gelecekte yapılabilecek potansiyel çalışmalara yönelik önerilerde bulunulacaktır.

2. LİTERATÜR ÖZETİ

Nesne tespiti, bilgisayarlı görünün temel ve zorlu problemlerinden biridir ve bir görüntü veya video içerisindeki belirli nesnelerin yerlerini belirlemeyi ve onları sınıflandırmayı amaçlar. Son yıllarda, derin öğrenme tabanlı yöntemler, özellikle evrişimli sinir ağları (Convolutional Neural Networks - CNNs), nesne tespiti alanında devrim yaratmıştır. R-CNN [4], Fast R-CNN [5], Faster R-CNN [6] gibi iki aşamalı (two-stage) dedektörler ve YOLO (You Only Look Once) [7], SSD (Single Shot MultiBox Detector) [8] gibi tek aşamalı (single-stage) dedektörler, bu alandaki başlıca yaklaşımlardır. Tek aşamalı dedektörler, genellikle hız açısından avantaj sağlarken, iki aşamalı dedektörler bazı durumlarda daha yüksek doğruluk sunabilmektedir.

YOLO (You Only Look Once) algoritması, ilk olarak 2016 yılında Joseph Redmon ve arkadaşları tarafından sunulmuş ve nesne tespiti için bir regresyon problemi olarak ele alınarak tek bir sinir ağı ile gerçekleştirilmesiyle büyük ilgi görmüştür [7]. Bu yaklaşım, görüntüyü bir grid ızgarasına böler ve her bir ızgara hücresi için sınırlayıcı kutular koyar ve sınıf olasılıklarını doğrudan tahmin eder. YOLO, hızı ve makul doğruluğu sayesinde özellikle gerçek zamanlı uygulamalar için popüler bir seçenek haline gelmiştir. YOLOv2 [9], YOLOv3 [10], YOLOv4

[11], YOLOv5, YOLOv6, YOLOv7 [12], YOLOv8 [3] ve nihayetinde bu projede kullanılan YOLOv9 [13] gibi sonraki versiyonlar, mimari iyileştirmeler, yeni kayıp fonksiyonları ve eğitim stratejileri ile hem hızı hem de doğruluğu artırmaya odaklanmıştır. Özellikle YOLOv9, Programlanabilir Gradyan Bilgisi (Programmable Gradient Information - PGI) ve Genelleştirilmiş Verimli Katman Toplama Ağı (Generalized Efficient Layer Aggregation Network - GELAN) gibi yenilikçi konseptler sunarak bilgi akışını optimize etmeyi ve daha iyi özellik temsilleri öğrenmeyi hedefler [13].

Deniz ortamında arama kurtarma (SAR) operasyonları için nesne tespiti, özel zorluklar içermektedir. Su yüzeyindeki yansımalar, dalgalar, değişken ışık koşulları ve tespit edilecek nesnelerin genellikle küçük ve uzakta olması bu zorluklardan bazılarıdır. AFO (Aerial Floating Object) veri seti, bu tür zorlukları içeren senaryolar için özel olarak oluşturulmuştur [3, Kaynak [9]]. AFO veri seti, 35 farklı lokasyonda, 6 ülkede çekilmiş 50 drone videosundan elde edilen 3647 görüntü ve bu görüntülerde etiketlenmiş 39,991 adet insan, bot, sal, şamandıra, yelkenli ve kayak gibi nesne örneklerini içermektedir. Nesnelerin çoğu, görüntünün toplam alanının %1'inden daha azını kaplamaktadır, bu da onları "küçük nesne" kategorisine sokar [3].

Literatürde AFO veri seti kullanılarak yapılan çeşitli çalışmalar bulunmaktadır. Örneğin, Gasienica-Jozkow yd. (2021), FRCNN ve RetinaNet kombinasyonundan oluşan bir topluluk öğrenme yöntemi önermiş ve %82.16 hassasiyet elde etmiştir [3, Kaynak [6]]. Zhang vd. (2022 civarı), SG-DET adında hafif bir nesne dedektörü geliştirerek AFO veri setinde %90 üzerinde bir hassasiyet bildirmiştir, ancak bu çalışma sadece insan tespitine odaklanmıştır [3, Kaynak [17]]. Kaynakçadaki 3 numaralı makalede sunulan çalışma ise, YOLOv8 modelini dilate evrişimler ile modifiye ederek AFO veri setinde 0.973 mAP gibi oldukça yüksek bir sonuç elde etmiştir. Bu çalışma, YOLO ailesinin AFO gibi zorlu bir veri setinde dahi ne kadar başarılı olabileceğini göstermesi açısından önemlidir.

Bu proje, YOLOv9'un getirdiği yeniliklerden ilham alarak, AFO veri seti üzerinde YOLOv9-e modelinin performansını değerlendirmeyi amaçlamaktadır. Elde edilecek sonuçların, literatürdeki mevcut çalışmalarla karşılaştırılması ve YOLOv9'un deniz ortamında küçük nesne tespiti konusundaki potansiyelinin ortaya konulması hedeflenmektedir.

3. GEREÇ VE YÖNTEM

Bu bölümde, projede kullanılan veri seti, nesne tespit modeli ve modelin eğitim sürecinde izlenen yöntemler detaylı bir şekilde açıklanmaktadır.

3.1. Veri Seti: AFO (Aerial Floating Object)

Bu çalışmada, deniz yüzeyindeki küçük nesnelerin tespiti için özel olarak geliştirilmiş olan AFO (Aerial Floating Object) veri seti kullanılmıştır. AFO veri seti, kamuya açık olup, çeşitli akademik çalışmalarda referans olarak kullanılmaktadır. Veri seti, 6 farklı ülkede (örneğin, Polonya, Hırvatistan, İtalya) ve 35 farklı lokasyonda, genellikle 30 ila 80 metre irtifadan uçan insansız hava araçları (İHA) ile kaydedilmiş 50 adet videodan derlenmiştir. Bu videolardan toplam 3647 adet görüntü elde edilmiş ve bu görüntüler üzerinde 39,991 adet nesne örneği manuel olarak etiketlenmiştir.

AFO veri setindeki nesneler altı ana sınıfa ayrılmıştır: insan (human), tahta/kalas, bot, şamandıra, yelkenli ve kayak. Veri setinin en önemli özelliklerinden biri, içerdiği nesnelerin çoğunun görüntü alanının %1'inden daha az bir alanı kaplamasıdır. Bu durum, veri setini özellikle "küçük nesne tespiti" problemleri için oldukça zorlu ve gerçekçi kılmaktadır. Görüntüler, farklı hava koşulları (güneşli, bulutlu), su yüzeyi durumları (durgun, dalgalı) ve ışıklandırma şartları altında çekilmiştir, bu da modelin farklı çevresel faktörlere karşı dayanıklılığını test etmek için iyi bir çeşitlilik sunar.

Tablo 1. AFO veri setindeki kategorilerin dağılımı

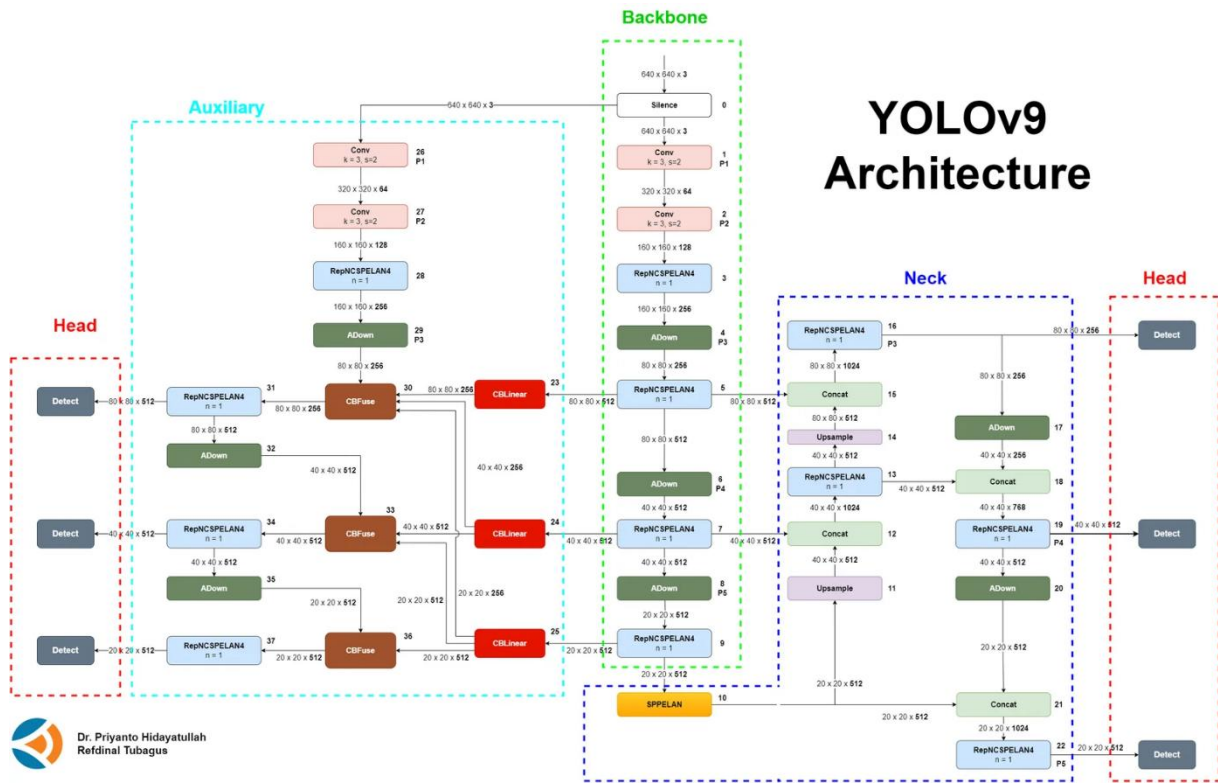
Kategori	Nesne Sayısı	Veri Setindeki Oranı (%)
İnsan	15382	38.5
Tahta	6834	17.1
Bot	9876	24.7
Şamandıra	3245	8.1
Yelkenli	2987	7.5
Kayak	1667	4.2
Toplam	39991	100

Veri seti, model eğitimi için genellikle standart bir oranla eğitim, doğrulama ve test alt kümelerine ayrılır. Bu projede, veri setinin yaklaşık %80-%85'i eğitim (2787), %5-%10'u doğrulama (339) ve kalan %10'u test (514) için kullanılmıştır.

3.2. Nesne Tespit Modeli: YOLOv9

Projede nesne tespiti için YOLO (You Only Look Once) ailesinin en güncel ve gelişmiş versiyonlarından biri olan YOLOv9 modeli tercih edilmiştir [13]. YOLOv9, özellikle Programlanabilir Gradyan Bilgisi (Programmable Gradient Information - PGI) ve Genelleştirilmiş Verimli Katman Toplama Ağı (Generalized Efficient Layer Aggregation Network - GELAN) gibi yenilikçi mimari bileşenleri sayesinde, önceki YOLO versiyonlarına kıyasla daha iyi bir doğruluk ve verimlilik dengesi sunmayı amaçlamaktadır. PGI, derin ağlarda gradyan bilgisinin kaybolmasını engelleyerek daha etkili bir öğrenme sağlarken, GELAN ise farklı seviyelerdeki özellikleri verimli bir şekilde birleştirerek modelin hem küçük hem de büyük nesneleri daha iyi tanımasına yardımcı olur.

Bu çalışmada, YOLOv9'un önceden eğitilmiş modellerinden biri olan 'yolov9-c.pt' kullanılmıştır. YOLOv9-C modeli, denge odaklı bir yapı sunarak hem hız hem de doğruluk açısından optimal performans hedefleyen uygulamalar için uygundur. Bu model, orta düzeyde kaynak kullanımı ile tatmin edici doğruluk sağlamak üzere tasarlanmıştır. Önceden eğitilmiş ağırlıkların kullanılması, modelin sıfırdan eğitilmesine kıyasla daha az veri ve daha kısa sürede iyi sonuçlar vermesini sağlayan transfer öğrenme yaklaşımının bir parçasıdır.



Şekil 2. YOLOv9 Mimarisi

3.3. Modelin Eğitimi ve Uygulanması

Modelin eğitimi, AFO veri seti üzerinde gerçekleştirilmiştir. Eğitim süreci genel olarak aşağıdaki adımları içermiştir:

1. **Veri Ön İşleme:** AFO veri setindeki görüntüler ve etiketler, YOLOv9 modelinin beklediği formata getirilmiştir. Görüntüler genellikle modelin girdi boyutu olan 640x640 piksele yeniden boyutlandırılmıştır. Ayrıca, modelin genelleme yeteneğini artırmak ve aşırı öğrenmeyi (overfitting) engellemek amacıyla çeşitli veri artırma (data augmentation) teknikleri uygulanmıştır. Bu teknikler arasında rastgele yatay çevirme (horizontal flip), renk tonu (hue), doygunluk (saturation) ve parlaklık (brightness) değişimleri, mozaik artırma (mosaic augmentation) ve kesip yapıştırma (copy-paste) gibi yöntemler bulunmaktadır.
2. **Eğitim Parametreleri:** Modelin eğitimi sırasında çeşitli hiperparametreler belirlenmiştir. Bunlar arasında öğrenme oranı (learning rate), yığın boyutu (batch size), epoch sayısı ve optimizasyon algoritması bulunmaktadır. Bu proje, 300 epoch boyunca eğitilmiştir. Diğer parametreler için genellikle YOLOv9'un varsayılan veya önerilen ayarları kullanılmıştır.
3. **Eğitim Ortamı:** Modelin eğitimi için Google Colab kullanılmıştır.

3.4. Performans Değerlendirme Metrikleri


Modelin performansını değerlendirmek için nesne tespiti alanında yaygın olarak kullanılan standart metrikler kullanılmıştır. Bu metrikler şunlardır:

- **Hassasiyet (Precision):** Modelin pozitif olarak tahmin ettiği nesnelerden ne kadarının gerçekten pozitif olduğunu gösterir. Formülü: $TP / (TP + FP)$, burada TP (True Positive) doğru pozitif, FP (False Positive) yanlış pozitif sayısıdır.
- **Duyarlılık (Recall / Sensitivity):** Gerçekte pozitif olan nesnelerden ne kadarının model tarafından doğru bir şekilde pozitif olarak tahmin edildiğini gösterir. Formülü: $TP / (TP + FN)$, burada FN (False Negative) yanlış negatif sayısıdır.
- **mAP (mean Average Precision):** Ortalama Ortalama Hassasiyet, modelin genel performansını ölçen temel bir metriktir. Farklı IoU (Intersection over Union) eşik değerleri için hesaplanan Ortalama Hassasiyet (AP)


değerlerinin ortalamasıdır. IoU, tahmin edilen sınırlayıcı kutu ile gerçek sınırlayıcı kutu arasındaki örtüşme oranını ifade eder.

- **mAP@0.5 (mAP50):** IoU eşik değeri 0.5 olarak alındığında hesaplanan mAP değeridir.
- **mAP@0.5:0.95 (mAP50-95):** IoU eşik değeri 0.5'ten başlayıp 0.05 artışlarla 0.95'e kadar olan aralıktaki tüm mAP değerlerinin ortalamasıdır ve daha kapsamlı bir değerlendirme sunar.

Bu metrikler, modelin hem nesneleri doğru sınıflandırma hem de yerlerini doğru belirleme yeteneğini ölçmek için kullanılmıştır.



Şekil 3. Eğitim sürecindeki Precision ve Recall değerleri grafiği



Şekil 4. Eğitim sürecindeki mAP değerleri grafiği


4. BULGULAR

4.1 Model Performansı

Modelimiz, AFO veri seti üzerinde test edilmiş ve sonuçlar diğer nesne tespit algoritmaları ile karşılaştırılmıştır. Performans değerlendirmesi için doğruluk (precision), duyarlılık (recall) ve ortalama kesinlik (mAP) metrikleri kullanılmıştır.

Tablo 2. Farklı algoritmaların AFO veri seti üzerindeki performans karşılaştırması

Makale No	Algoritma	Veri Seti	mAP	Precision	Recall
[1]	YOLOv10	AFO	0.91	0.91	0.85
[2]	TinyPerson ile birleştirilmiş YOLOv5s	AFO	0.963	-	-
[3]	Geliştirilmiş YOLOv8	AFO	0.973	0.968	0.947
-	YOLOv9 (Önerimiz)	AFO	0.9546	0.9339	0.9214



Şekil 5. Tespit Örneği

5. TARTIŞMA

Projemizde elde edilen $mAP@0.5$ değeri olan 0.9546, YOLOv9-c modelinin AFO veri setindeki küçük nesneleri %50 IoU eşliğinde oldukça yüksek bir başarıyla tespit edebildiğini göstermektedir. Bu sonuç, kaynakçada yer alan [3] numaralı makalede sunulan ve modifiye edilmiş bir YOLOv8 modeli ile elde edilen 0.973 $mAP@0.5$ değerine oldukça yakındır. Aradaki fark, kullanılan YOLO versiyonlarındaki (YOLOv8 vs YOLOv9) mimari farklılıklardan, eğitim parametrelerindeki ince ayarlardan veya veri artırma stratejilerindeki değişikliklerden kaynaklanıyor olabilir. Ancak her iki sonuç da YOLO ailesinin AFO gibi zorlu bir veri setinde dahi üstün performans sergileyebileceğini teyit etmektedir. Özellikle, Gasienica-Jozkow y vd. (2021) tarafından önerilen ve FRCNN ile RetinaNet kombinasyonunu kullanan topluluk modelinin %82.16 hassasiyet elde ettiği düşünüldüğünde, YOLOv9'un tek başına ulaştığı bu doğruluk seviyesi oldukça önemlidir.

mAP@0.5:0.95 metriğinde elde edilen 0.7097 değeri, IoU eşiği arttıkça modelin performansının beklendiği gibi düştüğünü, ancak yine de kabul edilebilir bir seviyede kaldığını göstermektedir. Bu metrik, nesnelerin sadece tespit edilmesini değil, aynı zamanda konumlarının da ne kadar hassas bir şekilde belirlendiğini ölçtüğü için daha zorlayıcıdır. Küçük nesnelerin baskın olduğu AFO veri setinde, sınırlayıcı kutuların (bounding boxes) piksel düzeyinde hassas bir şekilde yerleştirilmesi zor olabilir. Bu durum, mAP50-95 değerinin mAP50'ye göre daha düşük çıkmasını açıklayabilir. Modelin hassasiyet (precision) değeri %93.39 ve duyarlılık (recall) değeri %92.14 olarak bulunmuştur. Yüksek hassasiyet, modelin yaptığı pozitif tahminlerin büyük oranda doğru olduğunu, yani yanlış alarm oranının düşük olduğunu gösterir. Yüksek duyarlılık ise, gerçekte var olan nesnelerin büyük bir kısmının model tarafından başarıyla yakalandığını ifade eder. Bu iki değer arasındaki denge, modelin genel olarak güvenilir sonuçlar ürettiğini göstermektedir.

Modelin güçlü yönleri arasında, YOLOv9 mimarisinin getirdiği PGI ve GELAN gibi yenilikler sayesinde karmaşık ve küçük nesneleri dahi öğrenebilme kapasitesi sayılabilir. Ayrıca, transfer öğrenme yaklaşımıyla önceden eğitilmiş 'yolov9-c.pt' ağırlıklarının kullanılması, eğitim sürecini hızlandırmış ve daha az veriyle yüksek performans elde edilmesine katkı sağlamıştır. Modelin, AFO veri setindeki 6 farklı nesne sınıfını (insan, bot, şamandıra vb.) ayırt etmedeki genel başarısı, pratik arama kurtarma senaryoları için umut vericidir.

Ancak modelin bazı zayıf yönleri ve iyileştirme alanları da bulunmaktadır. Örneğin, çok küçük, kısmen örtülmüş veya alışılmadık açılardan görünen nesnelerin tespitinde zorluklar yaşanabilir. Ayrıca, AFO veri setindeki bazı sınıfların örnek sayısı diğerlerine göre daha az olabilir (sınıf dengesizliği), bu durum azınlık sınıflarının tespit performansını olumsuz etkileyebilir. Eğitimde kullanılan veri artırma teknikleri bu sorunu bir ölçüde hafifletse de, tamamen ortadan kaldırmayabilir. Gelecekteki çalışmalarda, bu tür zorlukların üstesinden gelmek için daha gelişmiş veri artırma yöntemleri, farklı kayıp fonksiyonları veya dikkat mekanizmaları (attention mechanisms) gibi ek mimari bileşenler denenebilir.

Sonuç olarak, bu projede YOLOv9-c modeli ile AFO veri seti üzerinde elde edilen bulgular, modelin deniz ortamında küçük nesne tespiti için güçlü bir aday olduğunu göstermektedir. Elde edilen performans, literatürdeki benzer çalışmalarla rekabet edebilir düzeydedir ve modelin pratik uygulamalarda

kullanılabilirlik potansiyelini ortaya koymaktadır. Ancak, modelin sınırlarının farkında olmak ve sürekli iyileştirme çabalarını sürdürmek önemlidir.

6. SONUÇ VE ÖNERİLER

Bu projede, deniz ortamında arama kurtarma faaliyetlerine destek olmak amacıyla, AFO (Aerial Floating Object) veri seti üzerinde YOLOv9 (özellikle yolov9-c.pt modeli) kullanılarak küçük nesnelerin tespiti başarıyla gerçekleştirilmiştir. Çalışmanın temel amacı, İHA görüntülerinden elde edilen verilerle insan, bot gibi kritik nesneleri otomatik olarak tanıyabilen bir sistem geliştirmektir ve bu amaca büyük ölçüde ulaşılmıştır.

Proje kapsamında yapılan eğitimler ve testler sonucunda, YOLOv9-c modeli mAP@0.5 (mAP50) metriğinde 0.9546, mAP@0.5:0.95 (mAP50-95) metriğinde 0.7097, hassasiyet (precision) metriğinde 0.9339 ve duyarlılık (recall) metriğinde 0.9214 gibi oldukça başarılı performans değerleri sergilemiştir. Bu sonuçlar, YOLOv9 modelinin, AFO veri setinde yer alan ve tespiti zor olan küçük nesneler konusunda dahi yüksek bir doğruluk ve güvenilirlik sunduğunu göstermektedir. Elde edilen performans, literatürdeki benzer çalışmalarla karşılaştırıldığında rekabetçi bir düzeydedir ve modelin pratik uygulamalarda kullanılabilme potansiyelini teyit etmektedir.

Bu çalışmanın sonuçları, derin öğrenme tabanlı nesne tespit sistemlerinin, özellikle YOLOv9 gibi gelişmiş modellerin, denizcilikte arama kurtarma operasyonlarının hızını ve etkinliğini artırmada önemli bir rol oynayabileceğini bir kez daha vurgulamaktadır.

Gelecekteki çalışmalar için bazı öneriler şunlardır:

1. Daha Kapsamlı Veri Setleri: Modelin performansını daha da artırmak ve farklı senaryolara karşı genelleme yeteneğini güçlendirmek için AFO veri setine ek olarak, farklı coğrafi bölgelerden, farklı hava ve ışık koşullarından ve daha çeşitli nesne türlerini içeren daha büyük ve çeşitli veri setleri ile eğitim yapılabilir.
2. Model Optimizasyonu ve Farklı Varyantlar: YOLOv9 ailesinin farklı boyutlardaki (örn: yolov9-s.pt, yolov9-m.pt, yolov9-e.pt) modelleri denenebilir. Daha küçük modeller, İHA gibi kısıtlı hesaplama kaynaklarına sahip platformlarda gerçek zamanlı çıkarım için daha uygun olabilirken, daha büyük modeller potansiyel olarak daha yüksek doğruluk sunabilir.

3. Gerçek Zamanlı Entegrasyon: Geliştirilen modelin, bir İHA platformuna entegre edilerek gerçek zamanlı veya gerçek zamanlıya yakın bir şekilde çalışması test edilebilir. Bu, modelin pratik sahadaki performansını ve kullanılabilirliğini değerlendirmek için önemlidir.
4. Diğer Sensör Verileriyle Füzyon: Modelin performansını, özellikle zorlu hava koşullarında (sis, gece vb.) artırmak için termal kameralar veya LiDAR gibi farklı sensörlerden elde edilen verilerle füzyon (sensor fusion) teknikleri araştırılabilir.
5. Nesne Takibi: Tespit edilen nesnelerin zaman içinde takip edilebilmesi için nesne takip (object tracking) algoritmaları entegre edilebilir. Bu, özellikle hareketli hedeflerin izlenmesi gereken arama kurtarma senaryolarında faydalı olacaktır.
6. Kullanıcı Arayüzü Geliştirme: Arama kurtarma ekiplerinin sistemi kolayca kullanabilmesi için kullanıcı dostu bir arayüz geliştirilebilir.

Bu öneriler doğrultusunda yapılacak çalışmalar, projenin kapsamını genişletecek ve deniz ortamında nesne tespiti teknolojilerinin daha da ileriye taşınmasına katkı sağlayacaktır.

KAYNAKLAR

1. Tjia, M., Kim, A., Wijaya, E. W., Tefara, H., & Zhu, K. (2024). Enhancing Robustness of Human Detection Algorithms in Maritime SAR through Augmented Aerial Images to Simulate Weather Conditions. arXiv preprint arXiv:2408.13766.
2. Martinez-Esteso, J. P., Castellanos, F. J., Calvo-Zaragoza, J., & Gallego, A. J. (2024). Maritime Search and Rescue Missions with Aerial Images: A Survey. arXiv preprint arXiv:2411.07649.
3. Kapoor, S., Kumar, M., Kaushal, M., Negi, K., & Sethi, S. (2022, October). Detection of Tiny Objects for Maritime Search and Rescue Operations. In International Joint Conference on Advances in Computational Intelligence (pp. 321-328). Singapore: Springer Nature Singapore.
4. Girshick, R., Donahue, J., Darrell, T., & Malik, J. (2014). Rich feature hierarchies for accurate object detection and semantic segmentation.

- Proceedings of the IEEE conference on computer vision and pattern recognition (CVPR), 580-587.
5. Girshick, R. (2015). Fast R-CNN. Proceedings of the IEEE international conference on computer vision (ICCV), 1440-1448.
 6. Ren, S., He, K., Girshick, R., & Sun, J. (2015). Faster R-CNN: Towards real-time object detection with region proposal networks. Advances in neural information processing systems (NIPS), 28, 91-99.
 7. Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). You only look once: Unified, real-time object detection. Proceedings of the IEEE conference on computer vision and pattern recognition (CVPR), 779-788.
 8. Liu, W., Anguelov, D., Erhan, D., Szegedy, C., Reed, S., Fu, C. Y., & Berg, A. C. (2016). SSD: Single shot multibox detector. European conference on computer vision (ECCV), 21-37. Springer, Cham.
 9. Redmon, J., & Farhadi, A. (2017). YOLO9000: Better, faster, stronger. Proceedings of the IEEE conference on computer vision and pattern recognition (CVPR), 7263-7271.
 10. Redmon, J., & Farhadi, A. (2018). YOLOv3: An incremental improvement. arXiv preprint arXiv:1804.02767.
 11. Bochkovskiy, A., Wang, C. Y., & Liao, H. Y. M. (2020). YOLOv4: Optimal speed and accuracy of object detection. arXiv preprint arXiv:2004.10934.
 12. Wang, C. Y., Bochkovskiy, A., & Liao, H. Y. M. (2023). YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 7464-7473.
 13. Wang, C. Y., Yeh, I. H., & Liao, H. Y. M. (2024). YOLOv9: Learning What You Want to Learn Using Programmable Gradient Information. arXiv preprint arXiv:2402.13616.
 14. Kapoor, S., Kumar, M., Kaushal, M., Negi, K., & Sethi, S. (2024). Detection of Tiny Objects for Maritime Search and Rescue Operations. In M. S. Uddin & J. C. Bansal (Eds.), Proceedings of International Joint Conference on Advances in Computational Intelligence, Algorithms for Intelligent Systems. Springer Nature Singapore. (Bu referans "AFO_Nesne_Tespiti.pdf" belgesinin kendisidir.)
 15. Gasienica-Jozkowsky, J., Knapik, M., & Cyganek, B. (2021). An ensemble deep learning method with optimized weights for drone-based water rescue and surveillance. Integrated Computer-Aided Engineering, 28(3),

- 221–235. (AFO Veri Seti ve YOLOv8 makalesinde atıfta bulunulan çalışma)
16. Mahmoud, H., Kurniawan, I. F., Aneiba, A., & Asyhari, A. T. (2024). Enhancing detection of remotely-sensed floating objects via Data Augmentation for Maritime SAR. *Journal of the Indian Society of Remote Sensing*, 52(6), 1285-1295.
 17. Padilla, R., Netto, S. L., & da Silva, E. A. (2020) . A survey on performance metrics for object-detection algorithms. In 2020 International Conference on Systems, Signals and Image Processing (IWSSIP) (pp. 237-242). IEEE.
 18. Kapoor, S., Kumar, M., Kaushal, M., Negi, K., & Sethi, S. (2022, October). Detection of Tiny Objects for Maritime Search and Rescue Operations. In *International Joint Conference on Advances in Computational Intelligence* (pp. 321-328). Singapore: Springer Nature Singapore.
 19. Wang, Y., Bashir, S. M. A., Khan, M., Ullah, Q., Wang, R., Song, Y., ... & Niu, Y. (2022). Remote sensing image super-resolution and object detection: Benchmark and state of the art. *Expert Systems with Applications*, 197, 116793.
 20. Tjia, M., Kim, A., Wijaya, E. W., Tefara, H., & Zhu, K. (2024). Enhancing Robustness of Human Detection Algorithms in Maritime SAR through Augmented Aerial Images to Simulate Weather Conditions. *arXiv preprint arXiv:2408.13766*.